高校1年　HS-MATH1-U05　データの分析

# 授業プリント　データの分析　授業プリント　教師用・指導ガイド付き

データの分析｜分散と標準偏差・相関係数・仮説検定の考え方

授業時間 100 分　対応する問題プリント：HS-MATH1-U05-EX

### 前提となる学習（未習なら先に復習）

- データの分布　四分位範囲と箱ひげ図：四分位数・箱ひげ図 JH-MATH-G2-U07
- データの活用：代表値 JH-MATH-G1-U07

### 授業前の確認

- 平均値・中央値・最頻値（中学1年）を求められる。
- 四分位数と箱ひげ図（中学2年）をかける。
- 平方根の計算と、確率の基本的な求め方を知っている。

### 発展・応用への接続

- 統計的な推測：確率分布と統計的推測 HS-MATHB-U02

### この授業の目標

1. 四分位数・箱ひげ図・外れ値の意味を理解し、データの散らばりを読み取れる。
2. 分散・標準偏差を定義に従って、また公式 $s^2 = \overline{x^2} - (\overline{x})^2$ を用いて計算でき、変量の変換による変化を説明できる。
3. 共分散と相関係数を計算して2つの変量の関係を判断し、仮説検定の考え方を用いて主張の妥当性を説明できる。

| 段階 | 時間 | 主な活動 |
|---|---|---|
| 導入：平均値が同じでも違うデータ | 10分 | 平均値が等しく散らばりが異なる2組のデータを比べ、散らばりの指標が必要なことを確認する |
| 四分位数・箱ひげ図・外れ値 | 15分 | 四分位範囲と外れ値の基準を確認する |
| 分散と標準偏差 | 25分 | 定義・計算公式の導出と例題1、変量の変換 |
| 散布図と相関係数 | 25分 | 共分散・相関係数の定義と計算（例題2）、相関と因果の区別 |
| 仮説検定の考え方 | 20分 | コイン投げの例で、仮説のもとで起こる確率を基準と比べて判断する（例題3） |
| まとめと確認 | 5分 | 確認問題3問、問題プリントA の課題指示 |

## 導入　平均値だけでは分からないこと

2つのクラスの小テストの平均点がどちらも 6 点でも、一方は全員が 5〜7 点、もう一方は 0 点から 10 点まで大きくばらついているかもしれない。データの特徴をとらえるには、代表値に加えて「散らばりの度合い」を数値で表す必要がある。さらに2つの変量の関係や、「偶然とは考えにくいか」を判断する方法も学ぶ。

- 散らばりの指標：範囲、四分位範囲、分散、標準偏差。
- 2つの変量の関係：散布図、共分散、相関係数。
- 判断の方法：仮説検定の考え方（ある仮定のもとで、その結果がどのくらい起こりやすいか）。

口頭で解説すべきポイント

- 平均値が等しい2組のデータをドットプロットで並べて示し、違いを言葉で説明させる。
  発問：2つのデータはどこが違うか。
  予想される反応：値の散らばり方が違う。
  タイミング：導入の冒頭
- この単元では「計算した値が何を意味するか」を必ず言葉で説明させる方針を伝える。

## 定義 四分位数と外れ値

データを小さい順に並べ、中央値で前半と後半に分ける（データの個数が奇数のときは中央値を除く）。前半の中央値を第1四分位数 $Q_1$、後半の中央値を第3四分位数 $Q_3$ という。$Q_3 - Q_1$ を四分位範囲という。

外れ値の目安： $Q_1 - 1.5(Q_3 - Q_1)$ より小さい値、または $Q_3 + 1.5(Q_3 - Q_1)$ より大きい値

使える条件・注意

- 四分位範囲は、極端な値の影響を受けにくい散らばりの指標である
- 外れ値の基準は1つの目安であり、問題文の定めに従う

口頭で解説すべきポイント

- データの個数が奇数・偶数の場合で、前半・後半の分け方が変わることを具体例で確認させる。
  注意：奇数個のとき中央値を前半・後半の両方に入れる誤りが多い。

## 定義 分散と標準偏差

変量 $x$ のデータを $x_1,\ x_2,\ \cdots,\ x_n$、平均値を $\overline{x}$ とする。各値と平均値の差 $x_k - \overline{x}$ を偏差といい、偏差の2乗の平均値を分散 $s^2$、その正の平方根を標準偏差 $s$ という。

$$s^2 = \frac{1}{n}\left\{(x_1 - \overline{x})^2 + (x_2 - \overline{x})^2 + \cdots + (x_n - \overline{x})^2\right\}, \qquad s = \sqrt{s^2}$$

使える条件・注意

- 偏差の和はつねに $0$ になるので、偏差をそのまま平均しても散らばりは測れない（2乗してから平均する）
- 標準偏差は元のデータと同じ単位をもつ

口頭で解説すべきポイント

- 偏差の和が $0$ になることを例で確かめさせ、なぜ2乗するのかを考えさせる。
  発問：偏差をそのまま平均するとどうなるか。
  予想される反応：いつも $0$ になる。

## 定理・公式 分散の計算公式と変量の変換

$$s^2 = \overline{x^2} - (\overline{x})^2, \qquad y = ax + b \text{ のとき } \overline{y} = a\overline{x} + b,\ s_y^2 = a^2 s_x^2,\ s_y = |a| s_x$$

使える条件・注意

- $\overline{x^2}$ は $x^2$ の平均値（2乗の平均）であり、$(\overline{x})^2$（平均の2乗）とは異なる
- 変換で $b$（全体を平行移動する量）は散らばりに影響しない

証明

1. $(x_k - \overline{x})^2 = x_k^2 - 2\overline{x}x_k + (\overline{x})^2$ を $k = 1$ から $n$ まで加えて $n$ で割る。
2. $\dfrac{1}{n}\sum x_k^2 = \overline{x^2}$、$\dfrac{1}{n}\sum x_k = \overline{x}$ より、$s^2 = \overline{x^2} - 2\overline{x}\cdot\overline{x} + (\overline{x})^2 = \overline{x^2} - (\overline{x})^2$。
3. $y_k = ax_k + b$ の平均は $\dfrac{1}{n}\sum(ax_k + b) = a\overline{x} + b$。
4. 偏差は $y_k - \overline{y} = a(x_k - \overline{x})$ となるので、2乗して平均すると $s_y^2 = a^2 s_x^2$。正の平方根をとって $s_y = |a| s_x$。

口頭で解説すべきポイント

- $s_y = a s_x$ と書く誤りに対し、$a = -2$ の例で標準偏差が負になる矛盾を示す。
  注意：$|a|$ の絶対値を落とす誤りが多い。
- 計算公式は、平均値が整数にならないデータや、2乗の平均が与えられている場合に有効であることを示す。

## 定義 共分散と相関係数

2つの変量 $x$, $y$ の組のデータについて、偏差の積 $(x_k - \overline{x})(y_k - \overline{y})$ の平均値を共分散 $s_{xy}$ という。共分散をそれぞれの標準偏差の積で割った値を相関係数 $r$ という。

$$s_{xy} = \frac{1}{n}\sum_{k=1}^{n}(x_k - \overline{x})(y_k - \overline{y}), \qquad r = \frac{s_{xy}}{s_x s_y}$$

使える条件・注意

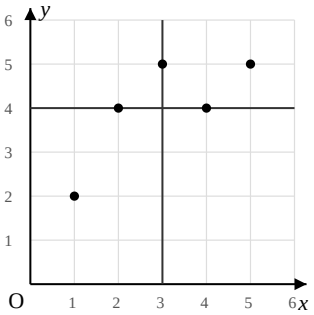
- $-1 \leqq r \leqq 1$ であり、$r$ が $1$ に近いほど強い正の相関、$-1$ に近いほど強い負の相関がある
- $r$ が $0$ に近いときは直線的な相関がほとんどない
- 相関があっても、一方が他方の原因であるとは限らない

口頭で解説すべきポイント

- 散布図を4つの区画に分け、偏差の積の符号が区画ごとに決まることから、共分散の符号の意味を説明する。

## 図解 散布図と偏差の積

平均値 $(\overline{x},\ \overline{y}) = (3,\ 4)$ を通る直線で区切ると、右上と左下の区画の点は偏差の積が正、左上と右下の区画の点は負になる。右上・左下に点が多いほど共分散は大きな正の値になる。




口頭で解説すべきポイント

- 点ごとに偏差の積の符号を書きこませ、合計の符号が散布図の傾向と一致することを確認させる。

## 定義　仮説検定の考え方

ある主張が正しいかどうかを判断するために、その主張に反する仮説（たとえば「コインは公正である」）を立てる。その仮説のもとで、実際に得られた結果以上に極端なことが起こる確率を求め、それがあらかじめ決めた基準（たとえば5%）より小さければ、仮説は正しくなかったと判断する。

使える条件・注意

- 確率が基準より小さいとき：「めったに起こらないことが起こった」と考え、仮説を誤りと判断する
- 確率が基準以上のとき：仮説が誤りとは判断できない（仮説が正しいと証明されたわけではない）

口頭で解説すべきポイント

- 「判断できない」と「正しいと証明された」の違いを強調する。
  注意：基準以上のとき「仮説は正しい」と結論する答案が多い。
  タイミング：例題3の後

## 例題　例題1　分散と標準偏差

データ 5，7，8，9，11 の分散と標準偏差を求めよ。

思考の糸口：定義どおり、平均値 → 偏差 → 偏差の2乗の平均 の順に求める。

1. 平均値は $\dfrac{5+7+8+9+11}{5}=8$。
2. 偏差は $-3,\ -1,\ 0,\ 1,\ 3$。
3. 偏差の2乗の和は $9+1+0+1+9=20$ なので、分散は $\dfrac{20}{5}=4$。
4. 標準偏差は $\sqrt{4}=2$。

答　分散 4、標準偏差 2

| よくある誤り | 正しい考え方 |
|---|---|
| 分散を $\dfrac{20}{4}=5$ とする（$n-1$ で割る） | 数学 I では個数 $n=5$ で割る |

口頭で解説すべきポイント

- 偏差の和が 0 になることを途中で確かめる習慣をつけさせる（計算ミスの発見に役立つ）。

## 例題 例題2　相関係数

5人の2つのテストの得点 $(x,\ y)$ が $(1,\ 2),\ (2,\ 4),\ (3,\ 5),\ (4,\ 4),\ (5,\ 5)$ である（架空のデータ）。相関係数を小数第3位を四捨五入して求めよ。

思考の糸口：$r=\dfrac{s_{xy}}{s_x s_y}$ で、分子・分母の $\dfrac{1}{n}$ は約分できるので、和のまま計算してよい。

1. $\overline{x}=3,\ \overline{y}=4$。$x$ の偏差：$-2,\ -1,\ 0,\ 1,\ 2$、$y$ の偏差：$-2,\ 0,\ 1,\ 0,\ 1$。
2. 偏差の積の和は $4+0+0+0+2=6$、$x$ の偏差の2乗の和は $10$、$y$ の偏差の2乗の和は $6$。
3. $r=\dfrac{6}{\sqrt{10}\sqrt{6}}=\dfrac{6}{\sqrt{60}}\fallingdotseq 0.7746$。

答　$r\fallingdotseq 0.77$

口頭で解説すべきポイント

- 共通の $\dfrac{1}{n}$ が約分できることを示し、計算量を減らす工夫として紹介する。

## 例題 例題3　仮説検定の考え方

あるコインを10回投げたところ、表が9回出た。「このコインは表が出やすい」と判断してよいか。基準となる確率を 5% として考えよ。

思考の糸口：主張と反対の「公正である」を仮定し、実際の結果以上に偏る確率を求めて基準と比べる。

1. 「コインは公正である（表と裏が出る確率はともに $\dfrac{1}{2}$）」という仮説を立てる。
2. 仮説のもとで、表が9回以上出る確率は $\dfrac{{}_{10}\mathrm{C}_9+{}_{10}\mathrm{C}_{10}}{2^{10}}=\dfrac{11}{1024}\fallingdotseq 0.011$。
3. これは $0.05$ より小さいので、仮説のもとではめったに起こらないことが起こったと考え、仮説は誤りと判断する。

答　表が出やすいと判断してよい

口頭で解説すべきポイント

- 「9回ちょうど」ではなく「9回以上」の確率を求める理由（それ以上に極端な場合も含めて評価する）を説明する。

## 板書案 板書案

| ① 散らばり | ② 相関 | ③ 仮説検定 |
|---|---|---|
| 四分位範囲 $Q_3-Q_1$ | $s_{xy}$＝偏差の積の平均 | 仮説：コインは公正 |
| 外れ値：$Q_1-1.5\times$IQR より小 | $r=\dfrac{s_{xy}}{s_x s_y}$、$-1\leqq r\leqq 1$ | 9回以上の確率 $\dfrac{11}{1024}\fallingdotseq 0.011$ |
| 分散 $s^2$＝偏差の2乗の平均 | 例題2：$r\fallingdotseq 0.77$ | $0.011<0.05$ → 仮説は誤り |
| $s^2=\overline{x^2}-(\overline{x})^2$ | 相関 ≠ 因果 | 基準以上 → 判断できない |
| $y=ax+b$：$s_y=\lvert a\rvert s_x$ | | |

口頭で解説すべきポイント

- ③では「仮説 → 確率 → 基準と比較 → 結論」の4段階を板書の型として示す。

## 指導ガイド　指導ガイド（口頭で補う要点）

| よくある誤り | 正しい考え方 |
|---|---|
| $\overline{x^2}$ と $(\overline{x})^2$ を同じものとして扱う | 2乗の平均と平均の2乗は一般に異なる（その差が分散） |
| $y=-2x+3$ のとき $s_y=-2s_x$ | $s_y=\lvert-2\rvert s_x=2s_x$ |
| 確率が 5% 以上なので仮説は正しいと証明された | 仮説が誤りとは判断できない、というだけである |

口頭で解説すべきポイント

- 分散の計算では、平均値が整数なら定義、そうでなければ計算公式、と使い分けを判断させる。
- 標準偏差を答えるときは単位（点、cm など）をつけさせ、分散との単位の違いに気づかせる。
  発問：身長（cm）のデータの分散の単位は何か。
  予想される反応：$\text{cm}^2$
- 相関係数の値だけでなく、散布図をかいて外れ値や曲線的な関係がないか確かめさせる。
- 相関があっても因果関係があるとは限らない例（気温とアイスの売上と水難事故の件数など、共通の要因がある場合）を口頭で紹介する。
  タイミング：相関係数の後
- 仮説検定では、基準の確率（有意水準）を先に決めておくこと、結論は「判断できる／できない」の形で書くことを徹底させる。

## まとめ　まとめ

- 分散＝偏差の2乗の平均＝$\overline{x^2}-(\overline{x})^2$、標準偏差＝$\sqrt{\text{分散}}$。$y=ax+b$ で $s_y=\lvert a\rvert s_x$。
- 相関係数 $r=\dfrac{s_{xy}}{s_x s_y}$（$-1 \leqq r \leqq 1$）。相関は因果を意味しない。
- 仮説検定：仮説のもとでの確率を基準と比べ、小さければ仮説は誤りと判断する。

## 確認　確認問題

1. データ 2，3，5，6，9 の分散を求めよ。
   → 平均 5、偏差の2乗の和 $9+4+0+1+16=30$ より 6
2. $x$ の標準偏差が 4 のとき、$y=-3x+1$ の標準偏差を求めよ。
   → $\lvert-3\rvert\times 4=12$
3. $s_{xy}=6$，$s_x=2$，$s_y=5$ のとき、相関係数を求めよ。
   → $\dfrac{6}{2\times 5}=0.6$

 © かながわコネクト教材プロジェクト（教育目的での複製可・再配布不可（著作権者の許諾が必要））